

Previsão de Resultados de Lutas do UFC com Aprendizagem de Máquina: um Estudo Comparativo de Modelos

Enzo Lozano Alan Carneiro Marcelo Marques
Departamento de Computação — Universidade Federal do Ceará
Aprendizagem de Máquina (2026.1) — Prof. César Lincoln C. Mattos

15 de junho de 2026

Resumo

O Ultimate Fighting Championship (UFC) é a principal organização de artes marciais mistas (MMA) do mundo, e prever o vencedor de uma luta é uma tarefa notoriamente difícil, dada a natureza explosiva do esporte. Neste trabalho formulamos a previsão do vencedor como um problema de classificação binária supervisionada e comparamos cinco modelos de aprendizagem de máquina — Regressão Logística, Random Forest, XGBoost, Máquinas de Vetores de Suporte (SVM) e uma Rede Neural (MLP) — sobre dados reais de **7.827 lutas** disputadas entre 1993 e 2024, coletadas do `ufcstats.com`. A partir dos atributos pré-luta dos atletas (idade, altura, envergadura, cartel, número de lutas, estilo de luta e taxas de vitória por nocaute, finalização e decisão), construímos uma representação *diferencial e antissimétrica* entre os dois lutadores, e adotamos uma avaliação por divisão temporal para simular o uso real do sistema. O melhor modelo (Random Forest) atingiu **60,2% de acurácia** e **AUC-ROC de 0,637** no conjunto de teste (lutas de 2021–2024), superando com folga os baselines, mas confirmando o baixo teto de previsibilidade do esporte reportado na literatura. A análise de importância indica que a *diferença de idade* e a *diferença de derrotas* são os fatores mais determinantes.

1 Introdução

O Ultimate Fighting Championship (UFC) popularizou as artes marciais mistas (MMA) e movimenta hoje uma indústria bilionária de eventos e apostas esportivas. Diferentemente de esportes coletivos, uma luta de MMA pode ser decidida em segundos por um único golpe, o que torna o resultado altamente incerto e atrai grande interesse na construção de modelos preditivos.

Este trabalho investiga, de forma sistemática, *em que medida é possível prever o vencedor de uma luta do UFC a partir de estatísticas conhecidas antes do combate*. Trata-se de um problema de **classificação binária**: dadas as características de dois lutadores, o modelo deve indicar qual deles vence. Como referência metodológica e fonte de dados utilizamos o projeto público *Punch Prophecy* [6], que coleta estatísticas do `ufcstats.com` [7].

Os objetivos do trabalho são: (i) montar um conjunto de dados real e limpo de lutas do UFC; (ii) propor uma representação diferencial e antissimétrica que elimine o viés de qual lutador é apresentado primeiro; (iii) treinar e comparar cinco modelos de aprendizagem de máquina sob uma metodologia rigorosa de avaliação temporal; e (iv) interpretar quais atributos mais influenciam o resultado. A motivação é tanto prática (apoio a análises esportivas e de apostas) quanto científica (quantificar o limite de previsibilidade do MMA).

2 Fundamentação Teórica

2.1 Descrição técnica do problema

Seja uma luta entre um lutador A e um oponente B . Associamos a cada atleta um vetor de atributos pré-luta e definimos a variável-alvo $y \in \{0, 1\}$, com $y = 1$ se A vence e $y = 0$ caso contrário. O objetivo é aprender uma função $f(\mathbf{x}) \approx P(y = 1 \mid \mathbf{x})$, onde $\mathbf{x}$ codifica a *diferença* entre os atributos de A e B . Essa formulação diferencial é natural: o que importa para o resultado é a vantagem relativa de um lutador sobre o outro, e não os valores absolutos.

Tabela 1: Atributos utilizados (medidos para cada lutador antes da luta).

Atributo	Descrição
Idade	Idade do atleta na data da luta (anos)
Altura	Altura (cm)
Envergadura	Alcance dos braços (cm)
Vitórias / Derrotas	Cartel acumulado no UFC
Lutas totais	Número de lutas anteriores (vitórias + derrotas)
Estilo de luta	<i>Stance</i> : orthodox, southpaw, switch ou outro
Taxa de nocaute	Fração das vitórias obtidas por KO/TKO
Taxa de finalização	Fração das vitórias obtidas por finalização
Taxa de decisão	Fração das vitórias obtidas por decisão dos juízes

2.2 Descrição dos dados

Utilizamos dois arquivos do projeto *Punch Prophecy*: `ufc_fights.csv`, com uma linha por luta e estatísticas *cumulativas pré-luta* de cada atleta, e `fighter_stats.csv`, com atributos físicos por lutador (2.539 atletas). Após descartar empates e resultados anulados, restaram **7.827 lutas** válidas, disputadas entre 1993 e 2024.

Para cada lutador foram considerados os atributos definidos pelo grupo, listados na Tabela 1. A saída do problema é o resultado da luta (vitória/derrota do lutador de referência).

2.3 Trabalhos similares

A previsão de resultados esportivos é um campo consolidado, e o MMA tem recebido atenção crescente. O projeto de referência *Punch Prophecy* [6] emprega regressão logística sobre estatísticas do `ufcstats.com` combinadas a odds de casas de apostas. De modo geral, a literatura e o mercado de apostas convergem para um teto de previsibilidade relativamente baixo: o favorito das casas vence tipicamente em torno de 60–65% das vezes, o que estabelece uma referência realista para qualquer modelo. Nosso trabalho se diferencia ao (i) comparar de forma controlada cinco famílias de modelos, (ii) adotar uma representação diferencial antissimétrica com aumento de dados por espelhamento, e (iii) usar divisão temporal estrita, evitando o vazamento de informação comum em avaliações por amostragem aleatória.

3 Metodologia

3.1 Preparação dos dados

As colunas de idade, altura e envergadura do arquivo de lutas estavam armazenadas como texto, com marcadores 'unknown' (e '0' para idade) indicando ausência; convertimos esses valores para NaN. Altura, envergadura e estilo de luta foram obtidos preferencialmente do `fighter_stats.csv` (texto limpo, com 99,3% de cobertura por nome), usando as colunas do arquivo de lutas apenas como reserva. Valores contínuos ainda ausentes (sobretudo envergadura) foram imputados pela mediana. O estilo de luta foi normalizado em quatro categorias (*orthodox*, *southpaw*, *switch* e *outro*).

3.2 Engenharia de atributos e espelhamento

Cada luta foi representada pela **diferença** entre os atributos do lutador e do oponente (lutador – oponente). Para o estilo de luta, usamos a diferença de indicadores por categoria (por exemplo, $d_stance_southpaw = \mathbb{I}[\text{lutador southpaw}] - \mathbb{I}[\text{oponente southpaw}]$) e um indicador simétrico de *estilos diferentes*. As taxas de vitória por método foram calculadas como a razão entre vitórias por aquele método e o total de vitórias. Ao todo, o modelo utiliza **14 atributos**.

Como cada luta aparece uma única vez no conjunto (de um canto arbitrário), e a representação diferencial é *antissimétrica*, aplicamos **espelhamento** no conjunto de treino: para cada luta criamos uma cópia com os cantos tro-

cados, negando todas as features diferenciais e invertendo o rótulo. Isso (i) impõe ao modelo a simetria desejada ($f(\mathbf{x}) = 1 - f(-\mathbf{x})$), (ii) elimina qualquer viés de ordem de apresentação e (iii) garante o balanceamento exato das classes.

3.3 Avaliação por divisão temporal

Para simular o uso real do sistema (prever eventos futuros) e evitar vazamento temporal, ordenamos as lutas por data e reservamos os **20% mais recentes** para teste. O conjunto de treino contém 6.261 lutas (1993–2021), que após o espelhamento totalizam **12.522 exemplos** balanceados; o conjunto de teste contém **1.566 lutas** (2021–2024), sem espelhamento.

3.4 Modelos

Comparamos cinco modelos de aprendizagem supervisionada, cobrindo modelos lineares, baseados em árvores, baseados em margem e conexionistas: **Regressão Logística** [4], **Random Forest** [1], **XGBoost** [2], **SVM** com kernel RBF [3] e uma **Rede Neural** (MLP). Cada modelo foi encapsulado em um *pipeline* com padronização das features (quando aplicável) para evitar vazamento durante a validação cruzada. Os hiperparâmetros foram ajustados por busca em grade com validação cruzada estratificada de 5 folds *somente sobre o treino*, usando a AUC-ROC como critério de seleção. Toda a implementação foi feita em Python com `scikit-learn` [5] e `xgboost`. Como referência, incluímos dois *baselines*: prever sempre a classe majoritária e prever o lutador com melhor cartel (maior número de vitórias).

3.5 Métricas de avaliação

Reportamos acurácia, precisão, revocação, F1, AUC-ROC e log-loss. A AUC-ROC mede a qualidade do *ranking* de probabilidades independentemente do limiar; a log-loss penaliza probabilidades mal calibradas; F1 resume o equilíbrio entre precisão e revocação. Complementarmente, analisamos a importância dos atributos (coeficientes da Regressão Logística e importância por permutação) e a calibração das probabilidades.

4 Experimentos

4.1 Configuração experimental

Todos os experimentos usaram semente aleatória fixa (42) para reprodutibilidade. O pipeline é dividido em cinco etapas (preparação, atributos, EDA, treino e avaliação), executáveis de forma independente.

4.2 Análise exploratória

A Figura 1 mostra o crescimento do número de lutas por ano, refletindo a expansão do UFC. A Figura 2 relaciona algumas features diferenciais à taxa de vitória observada no treino: lutadores mais jovens, com mais vitórias, maior envergadura e maior taxa de nocaute tendem a vencer mais, embora os efeitos sejam moderados — um primeiro indício do baixo teto de previsibilidade do esporte.

4.3 Seleção de modelos (validação cruzada)

A Tabela 2 resume a AUC-ROC obtida na validação cruzada do treino. Os modelos ficaram próximos entre si (AUC entre 0,612 e 0,626), com leve vantagem da Regressão Logística, o que sugere que a relação entre os atributos e o resultado é predominantemente *aditiva/linear* após a representação diferencial.

4.4 Desempenho no conjunto de teste

A Tabela 3 apresenta o desempenho no conjunto de teste temporal. Todos os modelos de aprendizagem superaram claramente os *baselines*. O **Random Forest** obteve o melhor desempenho geral (acurácia 0,602; AUC-ROC 0,637),




Figura 1: Número de lutas do UFC por ano no conjunto de dados (1993–2024).

Tabela 2: AUC-ROC por validação cruzada (5 folds) no conjunto de treino.

Modelo	AUC-ROC (CV)
Regressão Logística	0,626
Random Forest	0,622
XGBoost	0,622
Rede Neural (MLP)	0,614
SVM (RBF)	0,612

seguido de perto pelos demais. As curvas ROC (Figura 3) e as matrizes de confusão (Figura 4) confirmam um comportamento equilibrado entre as classes, sem viés para vitória ou derrota — efeito direto do espelhamento.

Um resultado notável é que o baseline “melhor cartel” fica praticamente no nível do acaso (acurácia 0,492; AUC 0,486) nas lutas recentes: escolher o lutador com mais vitórias, isoladamente, não é informativo. Os modelos completos alcançam ~60% porque combinam vários sinais fracos.

4.5 Importância dos atributos e calibração

A Figura 5 mostra os coeficientes da Regressão Logística e a importância por permutação. A **diferença de idade** é o atributo mais determinante (lutadores mais velhos vencem menos), seguida da **diferença de derrotas**. As taxas de nocaute e finalização e a envergadura também contribuem positivamente, enquanto o estilo de luta tem efeito marginal. Isso explica a fraqueza do baseline de cartel: o número absoluto de vitórias importa menos do que a idade e o histórico de derrotas. A curva de calibração (Figura 6) indica que as probabilidades previstas são razoavelmente confiáveis, ainda que conservadoras nos extremos.

4.6 Discussão

Os resultados são consistentes com o teto de previsibilidade do MMA reportado na literatura (~60–65%). A proximidade entre modelos lineares e não lineares sugere que ganhos adicionais virão mais de *melhores atributos* (por exemplo, estatísticas de desempenho dentro do octógono, sequência de vitórias/derrotas recentes, tempo de inatividade e mudança de categoria de peso) do que de modelos mais complexos. A divisão temporal e o espelhamento tornam a avaliação mais honesta, mas também mais difícil, pois o modelo é testado em lutadores e tendências possivelmente não vistos no treino.




Figura 2: Taxa de vitória em função de features diferenciais (binadas por quantis). A linha tracejada indica 50%.

5 Conclusão

Formulamos a previsão de lutas do UFC como classificação binária e comparamos cinco modelos de aprendizagem de máquina sobre 7.827 lutas reais, com uma metodologia cuidadosa de preparação de dados, representação diferencial antissimétrica com espelhamento e avaliação por divisão temporal. O melhor modelo (Random Forest) atingiu 60,2% de acurácia e AUC-ROC de 0,637, superando os baselines e ficando dentro do teto realista do esporte. A análise de importância destacou idade e histórico de derrotas como fatores preponderantes.

Como trabalhos futuros, propomos: (i) incorporar estatísticas detalhadas de desempenho por luta (golpes significativos, quedas, controle de solo); (ii) modelar a forma recente do atleta (janelas temporais e sequências de resultados); (iii) incorporar as odds das casas de apostas como atributo e como baseline forte; e (iv) explorar modelos específicos para dados longitudinais, como redes recorrentes ou *gradient boosting* com features temporais.

Contribuições dos Integrantes

- **Enzo Lozano:** coleta e preparação dos dados (limpeza, junção das tabelas, tratamento de valores ausentes) e análise exploratória.
- **Alan Carneiro:** engenharia de atributos, espelhamento, divisão temporal e implementação/ajuste dos modelos.
- **Marcelo Marques:** avaliação, geração de figuras e tabelas, análise de resultados e redação do artigo.

Referências

- [1] Leo Breiman. Random forests. *Machine Learning*, 45(1):5–32, 2001.

Tabela 3: Desempenho dos modelos no conjunto de teste temporal (lutas de 2021–2024). Em negrito, o melhor valor de cada métrica.

Modelo	Acurácia	Precisão	Revocação	F1	AUC-ROC	Log-loss
Baseline (classe majoritária)	0.497	0.000	0.000	0.000	–	–
Baseline (melhor cartel)	0.492	0.495	0.414	0.451	0.486	0.855
Regressão Logística	0.597	0.605	0.572	0.588	0.630	0.670
Random Forest	0.602	0.609	0.582	0.595	0.637	0.668
XGBoost	0.584	0.593	0.553	0.573	0.629	0.670
SVM (RBF)	0.596	0.601	0.591	0.596	0.623	0.671
Rede Neural (MLP)	0.596	0.601	0.591	0.596	0.631	0.669




Figura 3: Curvas ROC no conjunto de teste.

- [2] Tianqi Chen and Carlos Guestrin. XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD)*, pages 785–794, 2016.
- [3] Corinna Cortes and Vladimir Vapnik. Support-vector networks. *Machine Learning*, 20(3):273–297, 1995.
- [4] Trevor Hastie, Robert Tibshirani, and Jerome Friedman. *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. Springer, 2 edition, 2009.
- [5] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and E. Duchesnay. Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830, 2011.
- [6] Leo Tuckey. Punch prophecy: Predicting UFC fight outcomes. <https://github.com/leotuckey/Punch-Prophecy-Leo-Tuckey>, 2024. Acessado em junho de 2026.
- [7] Ultimate Fighting Championship. UFCStats – official UFC statistics. <http://ufcstats.com>. Acessado em junho de 2026.




Figura 4: Matrizes de confusão no conjunto de teste para os cinco modelos.




Figura 5: Importância dos atributos: coeficientes da Regressão Logística (esquerda) e importância por permutação em AUC (direita).




Figura 6: Curva de calibração do melhor modelo linear (Regressão Logística).