

Previsão de Resultados de Lutas do UFC com Aprendizagem de Máquina: um Estudo Comparativo de Modelos

Enzo Lozano Alan Carneiro Marcelo Marques
Departamento de Computação, Universidade Federal do Ceará
Aprendizagem de Máquina (2026.1), Prof. César Lincoln C. Mattos

22 de junho de 2026

Resumo

O Ultimate Fighting Championship (UFC) é a principal organização de artes marciais mistas (MMA) do mundo, e prever o vencedor de uma luta é uma tarefa notoriamente difícil, dada a natureza explosiva do esporte. Neste trabalho formulamos a previsão do vencedor como um problema de classificação binária supervisionada e comparamos cinco modelos de aprendizagem de máquina (Regressão Logística, Random Forest, XGBoost, Máquinas de Vetores de Suporte (SVM) e uma Rede Neural (MLP)) sobre dados reais de **7.004 lutas** disputadas entre 2008 e 2024, coletadas do `ufcstats.com`. A partir dos atributos pré-luta dos atletas, construímos uma representação *diferencial e antissimétrica* entre os dois lutadores com **23 atributos**, incluindo, além das características físicas e de cartel, estatísticas de desempenho dentro do octógono (golpes significativos dados e absorvidos, quedas e precisão), indicadores de forma recente (taxas de vitória nos últimos 2 e 5 anos) e proxies de durabilidade (derrotas por nocaute e taxa de lutas que vão à decisão). Adotamos uma avaliação por divisão temporal para simular o uso real do sistema. O melhor modelo (Random Forest) atingiu **62,5% de acurácia** e **AUC-ROC de 0,675** no conjunto de teste (lutas de 2022–2024), superando com folga os baselines e situando-se no teto de previsibilidade do esporte reportado na literatura. A análise de importância indica que a *diferença de idade* permanece o fator mais determinante, mas que as novas estatísticas de luta, em especial os *golpes significativos absorvidos* e a *precisão de golpes*, figuram entre os atributos mais informativos.

1 Introdução

O Ultimate Fighting Championship (UFC) popularizou as artes marciais mistas (MMA) e movimentou hoje uma indústria bilionária de eventos e apostas esportivas. Diferentemente de esportes coletivos, uma luta de MMA pode ser decidida em segundos por um único golpe, o que torna o resultado altamente incerto e atrai grande interesse na construção de modelos preditivos.

Este trabalho investiga, de forma sistemática, *em que medida é possível prever o vencedor de uma luta do UFC a partir de estatísticas conhecidas antes do combate*. Trata-se de um problema de **classificação binária**: dadas as características de dois lutadores, o modelo deve indicar qual deles vence. Como referência metodológica e fonte de dados utilizamos o projeto público *Punch Prophecy* [6], que coleta estatísticas do `ufcstats.com` [7].

Os objetivos do trabalho são: (i) montar um conjunto de dados real e limpo de lutas do UFC; (ii) propor uma representação diferencial e antissimétrica que elimine o viés de qual lutador é apresentado primeiro; (iii) enriquecer essa representação com atributos de desempenho intra-octógono e de forma recente; (iv) treinar e comparar cinco modelos de aprendizagem de máquina sob uma metodologia rigorosa de avaliação temporal; e (v) interpretar quais atributos mais influenciam o resultado. A motivação é tanto prática (apoio a análises esportivas e de apostas) quanto científica (quantificar o limite de previsibilidade do MMA).

Tabela 1: Atributos utilizados (medidos para cada lutador antes da luta), organizados por grupo.

Atributo	Descrição
<i>Grupo 1: diferenciais básicos</i>	
Idade	Idade do atleta na data da luta (anos)
Altura	Altura do atleta (cm)
Envergadura	Distância entre as pontas dos dedos com os braços abertos (cm)
Vitórias / Derrotas	Número acumulado de vitórias e derrotas do atleta no UFC
Lutas totais	Número de lutas anteriores no UFC (vitórias + derrotas)
Taxa de nocaute	Fração das vitórias do atleta obtidas por nocaute (KO/TKO)
Taxa de finalização	Fração das vitórias do atleta obtidas por finalização (submissão)
Taxa de decisão	Fração das vitórias do atleta obtidas por decisão dos juízes
Derrotas por nocaute	Nº de derrotas por KO/TKO; quanto maior, menor a resistência do atleta a golpes
Taxa de ida à decisão	Fração das lutas do atleta (vitórias + derrotas) que foram até a decisão dos juízes (proxy de durabilidade)
<i>Grupo 2: forma recente</i>	
Win-rate (5 anos)	Taxa de vitória do atleta nas lutas disputadas nos últimos 5 anos
Win-rate (2 anos)	Taxa de vitória do atleta nas lutas disputadas nos últimos 2 anos (mais sensível a mudanças recentes de forma)
<i>Grupo 3: estatísticas de luta (médias pré-luta)</i>	
Golpes signif. dados	Média de golpes significativos conectados pelo atleta por luta
Golpes signif. absorvidos	Média de golpes significativos recebidos pelo atleta por luta
Takedowns concluídos	Média de quedas (<i>takedowns</i>) bem-sucedidas por luta
Precisão de takedown	Fração das tentativas de queda do atleta que são bem-sucedidas
Precisão de golpes	Fração dos golpes significativos tentados pelo atleta que são conectados
<i>Grupo 4: estilo de luta</i>	
Estilo de luta	<i>Stance</i> do atleta: orthodox, southpaw, switch ou outro
Estilos diferentes	Indicador binário simétrico, igual a 1 quando os dois lutadores têm <i>stances</i> diferentes

2 Fundamentação Teórica

2.1 Descrição técnica do problema

Seja uma luta entre um lutador A e um oponente B . Associamos a cada atleta um vetor de atributos pré-luta e definimos a variável-alvo $y \in \{0, 1\}$, com $y = 1$ se A vence e $y = 0$ caso contrário. O objetivo é aprender uma função $f(\mathbf{x}) \approx P(y = 1 | \mathbf{x})$, onde $\mathbf{x}$ codifica a *diferença* entre os atributos de A e B . Essa formulação diferencial é natural: o que importa para o resultado é a vantagem relativa de um lutador sobre o outro, e não os valores absolutos.

2.2 Descrição dos dados

Utilizamos dois arquivos do projeto *Punch Prophecy*: `ufc_fights.csv`, com uma linha por luta e estatísticas *cumulativas pré-luta* de cada atleta, e `fighter_stats.csv`, com atributos físicos por lutador (2.538 atletas). Partindo de 7.961 lutas brutas, descartamos empates e resultados anulados e restringimos a análise às lutas a partir de **2008**, ano a partir do qual as estatísticas detalhadas de desempenho (golpes significativos, quedas e precisões) passam a ter boa cobertura. Após esses filtros, restaram **7.004 lutas** válidas, disputadas entre 2008 e 2024.

Para cada lutador, consideramos os atributos definidos por nosso grupo, organizados em quatro categorias e listados na Tabela 1: diferenciais físicos e de cartel, forma recente, estatísticas de desempenho intra-octógono e estilo de luta. A variável de saída do problema é o resultado da luta, codificado como vitória ou derrota do lutador de referência.

2.3 Trabalhos similares

A previsão de resultados esportivos é um campo consolidado, e o MMA tem recebido atenção crescente. O projeto de referência *Punch Prophecy* [6] emprega regressão logística sobre estatísticas do `ufcstats.com` combinadas a odds de casas de apostas. De modo geral, a literatura e o mercado de apostas convergem para um teto de previsibilidade relativamente baixo: o favorito das casas vence tipicamente em torno de 60–65% das vezes, o que estabelece uma referência realista para qualquer modelo. Nosso trabalho se diferencia ao (i) comparar de forma controlada cinco famílias de modelos, (ii) adotar uma representação diferencial antissimétrica com aumento de dados por espelhamento, (iii) enriquecer essa representação com atributos de desempenho intra-octógono e de forma recente, e (iv) usar divisão temporal estrita, evitando o vazamento de informação comum em avaliações por amostragem aleatória.

3 Metodologia

3.1 Preparação dos dados

As colunas de idade, altura e envergadura do arquivo de lutas estavam armazenadas como texto, com marcadores 'unknown' (e '0' para idade) indicando ausência; convertemos esses valores para NaN. Altura, envergadura e estilo de luta foram obtidos preferencialmente do `fighter_stats.csv` (texto limpo, com 99,3% de cobertura por nome), usando as colunas do arquivo de lutas apenas como reserva. Valores contínuos ainda ausentes (sobretudo envergadura) foram imputados pela mediana. O estilo de luta foi normalizado em quatro categorias (*orthodox*, *southpaw*, *switch* e *outro*).

3.2 Engenharia de atributos e espelhamento

Cada luta foi representada pela **diferença** entre os atributos do lutador e do oponente (lutador – oponente), organizados nos quatro grupos da Tabela 1. Além dos diferenciais físicos e de cartel, incorporamos: (i) proxies de *durabilidade* (número de derrotas por nocaute e a fração de lutas que terminam em decisão); (ii) *forma recente* (taxas de vitória nas janelas de 2 e 5 anos anteriores à luta); e (iii) *estatísticas de desempenho* dentro do octógono (golpes significativos dados e absorvidos por luta, takedowns, precisão de takedown e precisão de golpes), todas calculadas como médias estritamente pré-luta para evitar vazamento. Para o estilo de luta, usamos a diferença de indicadores por categoria (por exemplo, $d_stance_southpaw = \mathbb{I}[\text{lutador southpaw}] - \mathbb{I}[\text{oponente southpaw}]$) e um indicador simétrico de *estilos diferentes*. As taxas de vitória por método foram calculadas como a razão entre vitórias por aquele método e o total de vitórias. Ao todo, o modelo utiliza **23 atributos**.

Como cada luta aparece uma única vez no conjunto (de um canto arbitrário), e a representação diferencial é *antissimétrica*, aplicamos **espelhamento** no conjunto de treino: para cada luta criamos uma cópia com os cantos trocados, negando todas as features diferenciais e invertendo o rótulo. Isso (i) impõe ao modelo a simetria desejada ($f(\mathbf{x}) = 1 - f(-\mathbf{x})$), (ii) elimina qualquer viés de ordem de apresentação e (iii) garante o balanceamento exato das classes.

3.3 Avaliação por divisão temporal

Para simular o uso real do sistema (prever eventos futuros) e evitar vazamento temporal, ordenamos as lutas por data e reservamos os **20% mais recentes** para teste. O conjunto de treino contém 5.603 lutas (2008–2022), que após o espelhamento totalizam **11.206 exemplos** balanceados; o conjunto de teste contém **1.401 lutas** (2022–2024), sem espelhamento.

3.4 Modelos

Comparamos cinco modelos de aprendizagem supervisionada, cobrindo modelos lineares, baseados em árvores, baseados em margem e conexionistas: **Regressão Logística** [4], **Random Forest** [1], **XGBoost** [2], **SVM** com kernel RBF [3] e uma **Rede Neural** (MLP). Cada modelo foi encapsulado em um *pipeline* com padronização das features (quando aplicável) para evitar vazamento durante a validação cruzada. Os hiperparâmetros foram ajustados por busca em grade com validação cruzada estratificada de 5 folds *somente sobre o treino*, usando a AUC-ROC como critério




Figura 1: Número de lutas do UFC por ano no conjunto de dados (1993–2024); a modelagem utiliza apenas as lutas a partir de 2008.

de seleção. Toda a implementação foi feita em Python com `scikit-learn` [5] e `xgboost`. Como referência, incluímos dois *baselines*: prever sempre a classe majoritária e prever o lutador com melhor cartel (maior número de vitórias).

3.5 Métricas de avaliação

Reportamos acurácia, precisão, revocação, F1, AUC-ROC e log-loss. A AUC-ROC mede a qualidade do *ranking* de probabilidades independentemente do limiar; a log-loss penaliza probabilidades mal calibradas; F1 resume o equilíbrio entre precisão e revocação. Complementarmente, analisamos a importância dos atributos (coeficientes da Regressão Logística e importância por permutação) e a calibração das probabilidades.

4 Experimentos

4.1 Configuração experimental

Todos os experimentos usaram semente aleatória fixa (42) para reprodutibilidade. O pipeline é dividido em cinco etapas (preparação, atributos, EDA, treino e avaliação), executáveis de forma independente.

4.2 Análise exploratória

A Figura 1 mostra o crescimento do número de lutas por ano, refletindo a expansão do UFC, e evidencia também a baixa cobertura de estatísticas detalhadas no período inicial, que motivou o recorte a partir de 2008. A Figura 2 relaciona algumas features diferenciais à taxa de vitória observada no treino: lutadores mais jovens, com mais vitórias, maior envergadura e maior taxa de nocaute tendem a vencer mais, embora os efeitos sejam moderados, o que é um primeiro indício do baixo teto de previsibilidade do esporte.




Figura 2: Taxa de vitória em função de features diferenciais (binadas por quantis). A linha tracejada indica 50%.

4.3 Seleção de modelos (validação cruzada)

A Tabela 2 resume a AUC-ROC obtida na validação cruzada do treino. Os modelos ficaram próximos entre si (AUC entre 0,617 e 0,634), com leve vantagem da Regressão Logística, o que sugere que a relação entre os atributos e o resultado é predominantemente *aditiva/linear* após a representação diferencial.

4.4 Desempenho no conjunto de teste

A Tabela 3 apresenta o desempenho no conjunto de teste temporal. Todos os modelos de aprendizagem superaram claramente os baselines. O **Random Forest** obteve o melhor desempenho geral (acurácia 0,625; AUC-ROC 0,675), seguido de perto pelos demais. As curvas ROC (Figura 3) e as matrizes de confusão (Figura 4) confirmam um comportamento equilibrado entre as classes, sem viés para vitória ou derrota, efeito direto do espelhamento. Esse resultado confirma o valor das estatísticas de desempenho intra-octógono e de forma recente incorporadas à representação.

Um resultado notável é que o baseline “melhor cartel” fica abaixo do nível do acaso (acurácia 0,489; AUC 0,481) nas lutas recentes: escolher o lutador com mais vitórias, isoladamente, não é informativo. Os modelos completos alcançam ~62% porque combinam vários sinais fracos.

Tabela 2: AUC-ROC por validação cruzada (5 folds) no conjunto de treino.

Modelo	AUC-ROC (CV)
Regressão Logística	0,634
XGBoost	0,628
Random Forest	0,623
SVM (RBF)	0,618
Rede Neural (MLP)	0,617

Tabela 3: Desempenho dos modelos no conjunto de teste temporal (lutas de 2022–2024). Em negrito, o melhor valor de cada métrica.

Modelo	Acurácia	Precisão	Revocação	F1	AUC-ROC	Log-loss
Baseline (classe majoritária)	0,492	0,000	0,000	0,000	–	–
Baseline (melhor cartel)	0,489	0,497	0,414	0,452	0,481	0,860
Regressão Logística	0,612	0,624	0,597	0,610	0,665	0,653
Random Forest	0,625	0,636	0,612	0,624	0,675	0,659
XGBoost	0,622	0,629	0,622	0,626	0,663	0,654
SVM (RBF)	0,606	0,615	0,600	0,607	0,644	0,663
Rede Neural (MLP)	0,619	0,633	0,596	0,614	0,661	0,659




Figura 3: Curvas ROC no conjunto de teste.




Figura 4: Matrizes de confusão no conjunto de teste para os cinco modelos.

4.5 Importância dos atributos e calibração

A Figura 7 mostra os coeficientes da Regressão Logística e a importância por permutação. A **diferença de idade** permanece o atributo mais determinante (lutadores mais velhos vencem menos). Em seguida, destacam-se os **golpes significativos absorvidos** (menor defesa, menor chance de vitória), a **precisão de golpes** e a **forma recente** (win-rate de 5 anos), além da já conhecida *diferença de derrotas*. Esse resultado indica que as estatísticas de desempenho intra-octógono, ou seja, o quanto o atleta acerta e o quanto apanha, são mais informativas do que o cartel absoluto. As taxas de finalização, o número de lutas totais e o estilo de luta têm efeito marginal. A curva de calibração (Figura 8) indica que as probabilidades previstas são razoavelmente confiáveis, ainda que conservadoras nos extremos.

4.6 Discussão

Os resultados são consistentes com o teto de previsibilidade do MMA reportado na literatura (~60–65%), agora no limite superior dessa faixa graças ao conjunto de atributos ampliado. A proximidade entre modelos lineares e não lineares sugere que ganhos adicionais virão mais de *melhores atributos* (como demonstrado pela incorporação das estatísticas de luta e da forma recente) do que de modelos mais complexos. A divisão temporal e o espelhamento tornam a avaliação mais honesta, mas também mais difícil, pois o modelo é testado em lutadores e tendências possivelmente não vistos no treino.

5 Aplicação Web: MuchaLutcha MatchMaker

Para tornar os modelos treinados utilizáveis na prática e ilustrar o uso real do sistema, desenvolvemos uma **aplicação web** (*MuchaLutcha MatchMaker*) que permite simular o confronto entre quaisquer dois lutadores e obter a probabilidade de vitória prevista. A aplicação serve, ao mesmo tempo, como demonstrador da metodologia descrita nas seções anteriores e como ferramenta interativa de exploração.

5.1 Arquitetura

O *back-end* foi implementado em Flask (Python) e carrega, ao iniciar, os cinco modelos treinados (`.joblib`) e o conjunto de dados processado, reutilizando exatamente o mesmo *pipeline* de engenharia de atributos do treino, de modo a garantir consistência entre treino e inferência. O servidor expõe três endpoints JSON: (i) `/api/rankings`, que faz *scraping* ao vivo dos rankings oficiais do `ufc.com` (com cache de 10 minutos) para popular as divisões com os atletas atuais; (ii) `/api/fighter/<nome>`, que recupera as estatísticas pré-luta de um atleta no conjunto de dados local, com busca tolerante a variações de nome; e (iii) `/api/predict`, que recebe os atributos dos dois lutadores e devolve a probabilidade de cada modelo e a do *ensemble*. O *front-end* é uma interface web que monta o vetor diferencial de 23 atributos a partir das estatísticas dos dois cantos e exibe o resultado.

5.2 Funcionalidades

A interface oferece: (a) seleção de lutadores reais a partir dos rankings atuais de cada categoria de peso; (b) um modo livre, sem restrição de divisão, permitindo qualquer confronto entre quaisquer atletas; (c) a criação de um *lutador customizado*, com estatísticas definidas pelo usuário, para testar cenários hipotéticos; (d) um seletor de *luta de título*, que alterna entre 3 e 5 *rounds* e ativa o ajuste do atributo de durabilidade (`d_dec_rate_overall`) descrito na metodologia; e (e) o carregamento assíncrono das fotos dos atletas a partir do `ufc.com`. A previsão final é apresentada como a média das probabilidades dos cinco modelos (*ensemble*), acompanhada do detalhamento por modelo e de um comparativo lado a lado dos atributos (*tale of the tape*), conforme as Figuras 5 e 6.




Figura 5: Comparativo de atributos (*tale of the tape*) entre os dois lutadores selecionados na aplicação web.




Figura 6: Tela de resultado da previsão: probabilidade do *ensemble* e detalhamento por modelo.

6 Conclusão

Formulamos a previsão de lutas do UFC como classificação binária e comparamos cinco modelos de aprendizagem de máquina sobre 7.004 lutas reais, com uma metodologia cuidadosa de preparação de dados, uma representação diferencial antissimétrica de 23 atributos (enriquecida com estatísticas de desempenho intra-octógono e indicadores de forma recente) e avaliação por divisão temporal. O melhor modelo (Random Forest) atingiu 62,5% de acurácia e AUC-ROC de 0,675, superando os baselines e situando-se no teto realista do esporte. A análise de importância destacou a idade, mas também os golpes absorvidos, a precisão de golpes e a forma recente como fatores preponderantes.

Como trabalhos futuros, propomos: (i) incorporar as odds das casas de apostas como atributo e como baseline forte; (ii) modelar explicitamente sequências de resultados e tempo de inatividade (*layoff*) entre lutas; (iii) tratar mudanças de categoria de peso e cortes de peso; e (iv) explorar modelos específicos para dados longitudinais, como redes recorrentes ou *gradient boosting* com features temporais.




Figura 7: Importância dos atributos: coeficientes da Regressão Logística (esquerda) e importância por permutação em AUC (direita).




Figura 8: Curva de calibração do melhor modelo linear (Regressão Logística).

Contribuições dos Integrantes

- **Enzo Lozano:** coleta e preparação dos dados (limpeza, junção das tabelas, tratamento de valores ausentes) e análise exploratória.
- **Alan Carneiro:** representação diferencial base, espelhamento, divisão temporal e implementação/ajuste dos modelos.
- **Marcelo Marques:** novos atributos (estatísticas de desempenho intra-octógono, forma recente e proxies de durabilidade), avaliação, geração de figuras e tabelas, análise de resultados e redação do artigo.

Referências

- [1] Leo Breiman. Random forests. *Machine Learning*, 45(1):5–32, 2001.
- [2] Tianqi Chen and Carlos Guestrin. XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD)*, pages 785–794, 2016.
- [3] Corinna Cortes and Vladimir Vapnik. Support-vector networks. *Machine Learning*, 20(3):273–297, 1995.
- [4] Trevor Hastie, Robert Tibshirani, and Jerome Friedman. *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. Springer, 2 edition, 2009.
- [5] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and E. Duchesnay. Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830, 2011.
- [6] Leo Tuckey. Punch prophecy: Predicting UFC fight outcomes. <https://github.com/leotuckey/Punch-Prophecy-Leo-Tuckey>, 2024. Acessado em junho de 2026.
- [7] Ultimate Fighting Championship. UFCStats – official UFC statistics. <http://ufcstats.com>. Acessado em junho de 2026.